

Projet Final

ETL & Pipeline Orchestration | ESILV MSc A4 | MACSIN4A2125

ETL & Pipeline Orchestration | ESILV MSc A4 | MACSIN4A2125

Professeur : Murali Krishna MOPIDEVI

Cours : ETL & Pipeline Orchestration (24h - 3 ECTS)

Etablissement : ESILV Paris - MSc Informatique Avancee, Annee 4

Evaluation : Projet Final (60% de la note finale) + Presence et Participation (40%)

Session de travail : 16 Juin 2026 | **Presentation finale :** 18 Juin 2026

Vue d'ensemble

Le projet final represente **60% de votre note finale**, les 40% restants etant bases sur la presence et la participation. Il vous donne l'opportunité de concevoir et de construire un pipeline de donnees complet de bout en bout, qui combine tout ce qui a ete vu durant les cours : ingestion, transformation, orchestration, streaming et visualisation.

Vous avez jusqu'au **16 Juin 2026** pour terminer votre projet - environ 3 semaines, plus la journee de travail en classe du 16 Juin. Chaque etudiant travaille **individuellement**. Les projets en groupe ne sont pas autorises.

Enregistrez votre idee rapidement. Ouvrez le fichier Excel dans Teams (`project_work.xls`) et renseignez votre idee de projet des que possible. La selection se fait selon le principe du premier arrive, premier servi - deux etudiants ne peuvent pas utiliser la meme idee ou le meme jeu de donnees.

Calendrier et Dates Importantes

Date	Etape
16 Juin 2026	Session de travail en classe - apportez votre projet fonctionnel
18 Juin 2026	Presentations finales (5 a 7 minutes chacune, en presentiel)
18 Juin 2026	Soumission du code et de la documentation via message personnel Teams

Exigences Techniques

Votre projet doit implementer un pipeline de donnees complet comprenant tous les elements suivants :

1. Composant ETL (Batch)

- ▶ Ingerer des donnees brutes depuis une source (API, fichier, base de donnees ou scraping web)
- ▶ Appliquer des transformations : nettoyage, enrichissement, cast de types, deduplication
- ▶ Charger dans un stockage cible (PostgreSQL, DuckDB, MinIO ou similaire)
- ▶ Le pipeline doit etre **idempotent** (pouvant etre relance sans dupliquer les donnees)

2. Composant ELT (Transformations SQL)

- ▶ Donnees brutes chargees d'abord dans une couche de staging
- ▶ Transformations SQL appliquees par-dessus (vues, agregations ou modeles dbt)
- ▶ Au moins une table analytique ou de reporting produite depuis la couche brute

3. Composant Streaming

- ▶ Au moins un flux de donnees en temps reel ou quasi-temps reel via **Kafka**
- ▶ Un consommateur lit et traite le flux (Flink, Spark ou consommateur Python simple)
- ▶ Les resultats sont ecrits dans un sink (table de base de donnees ou dashboard)

4. Orchestration

- ▶ Les etapes du pipeline sont coordonnees avec **Apache Airflow** (ou Prefect/Dagster)
- ▶ Le DAG inclut une planification, des tentatives et des dependances entre taches

5. Dashboard en Temps Reel

- ▶ Un dashboard en direct construit avec **Streamlit**, **Grafana** ou similaire
- ▶ Affiche au moins 5 visualisations pertinentes, rafraichies depuis la sortie du pipeline

Livrables du Projet

Ce qu'il faut construire

- ▶ [] Idee de projet enregistree dans `project_work.xls` sur Teams
- ▶ [] Diagramme d'architecture montrant le flux de donnees de bout en bout
- ▶ [] Pipeline ETL fonctionnel (batch)
- ▶ [] Couche ELT fonctionnelle (transformations SQL)
- ▶ [] Composant de streaming Kafka
- ▶ [] DAG d'orchestration ou workflow
- ▶ [] Dashboard en temps reel

Ce qu'il faut soumettre (apres votre presentation, via message personnel Teams)

- ▶ [] Code complet du projet (lien GitHub ou zip)
- ▶ [] `README.md` expliquant ce que fait le projet
- ▶ [] `SETUP.md` ou equivalent expliquant comment lancer le projet en local
- ▶ [] Diagramme d'architecture (image ou fichier draw.io)
- ▶ [] Support de presentation PowerPoint ou PDF (recommande)

Exigences de Presentation

Chaque etudiant dispose de **5 a 7 minutes** pour presenter. Vous devez couvrir :

- 1 **Cas d'usage** - quel probleme votre pipeline resout-il ? avec quelles donnees travaillez-vous ?
- 2 **Architecture** - presentez votre diagramme d'architecture
- 3 **Demo en direct** - executez votre code et montrez les donnees circulant dans le pipeline
- 4 **Dashboard** - montrez le dashboard en direct avec des donnees reelles ou simulees

5 Flux de données - expliquez chaque étape depuis la source jusqu'à la visualisation

Preparez votre environnement de demo avant le jour de la presentation. Venez avec votre ordinateur portable et tout ce qui fonctionne. Il n'y aura pas de temps pour corriger des problèmes de configuration pendant la session.

Sources de Données

Vous pouvez utiliser l'une des sources suivantes :

- ▶ **APIs REST publiques** (meteo, finance, transport, reseaux sociaux, sport, etc.)
- ▶ **Scraping web** (BeautifulSoup, Scrapy, Playwright)
- ▶ **Jeux de données publics** téléchargés et rejoués via un producteur Kafka
- ▶ **Données simulées/synthétiques** générées avec Faker ou des scripts personnalisés

Outils et Infrastructure

Vous pouvez exécuter votre projet sur :

Option	Details
Votre propre machine	Windows, Mac ou Linux avec Docker Desktop
AWS EC2	Instance free-tier t3.micro ou votre instance de cours
Autre cloud	GCP, Azure, DigitalOcean (votre propre compte et à vos frais)

Outils principaux couverts dans ce cours que vous devriez utiliser :

Couche	Outils Recommandes
Ingestion	Python (requests, httpx), producteur Kafka
Stockage	PostgreSQL, DuckDB, MinIO (compatible S3)
Transformation	pandas, dbt, SQL
Streaming	Apache Kafka, Flink, PySpark
Orchestration	Apache Airflow
Visualisation	Streamlit, Plotly
Infrastructure	Docker Compose, AWS EC2

Vous n'etes pas limite a ces outils - si vous en utilisez d'autres, soyez pret a justifier votre choix.

Criteres d'Evaluation

Votre note est repartie comme suit :

Composant	Poids	Ce qui est evalue
Projet Final	60%	Voir detail ci-dessous
Presence et Participation	40%	Present les 16 et 18 Juin ; engagement actif en cours

Au sein du **score projet (60%)**, les points sont distribues ainsi :

Critere	Poids	Ce qui est evalue
Implementation technique	40%	Le pipeline fonctionne de bout en bout, code propre et idempotent, tous les composants requis presents
Cas d'usage et creativite	25%	Le probleme est pertinent, le jeu de donnees est original, le pipeline apporte une valeur reelle
Technologies utilisees	20%	Choix de stack appropries, utilisation correcte des outils, complexite de l'integration
Qualite de la presentation	15%	Clarte, structure, demo en direct, capacite a repondre aux questions

Notes Importantes

La presence les 16 et 18 Juin 2026 est obligatoire.

- ▶ Je prendrai personnellement les presences les deux jours.
- ▶ Chaque etudiant doit presenter son projet **en presentiel**.
- ▶ Les soumissions en ligne ou les presentations a distance ne seront **pas** acceptees.
- ▶ Les projets soumis apres le **18 Juin 2026** ne seront pas pris en compte.
- ▶ Integrite academique : tout le code doit etre votre propre travail. Vous pouvez utiliser des bibliotheques et consulter la documentation, mais la conception et l'implementation du pipeline doivent etre originales.

Merci. Bonne chance pour vos projets - j'ai hate de voir ce que vous allez construire.

Murali Krishna MOPIDEVI

Professeur, ETL & Pipeline Orchestration

ESILV Paris